



AGH

**AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE**

Teoria Sterowania
Optymalizacja Parametryczna


Maciej Różewicz, Dariusz Cieślak

2025

1 Wprowadzenie

1.1 Struktura układu regulacji automatycznej

W czasie realizacji ćwiczenia rozważać będziemy układ regulacji automatycznej (URA), w którym wyróżniamy dynamikę obiektu sterowania $G_O(s)$ i regulatora $G_R(s)$, a także sygnał wartości zadanej $R(s)$ i dwa nieznane sygnały zakłócające: zakłócenie obciążeniowe $D(s)$ i zakłócenie pomiarowe $N(s)$. Schemat takiego URA pokazano na rysunku (1).



Rysunek 1: Schemat układu regulacji z zaznaczonymi sygnałami: $R(s)$ - wartość zadana, $E(s)$ - uchyb regulacji, $U(s)$ - sterowanie, $D(s)$ - zakłócenie obciążeniowe (obciążenie), $V(s)$ - wejście obiektu, $O(s)$ - wyjście obiektu, $Y(s)$ - wyjście układu regulacji.

Układ taki opisuje się zwykle kilkoma transmitancjami przedstawionymi w tabeli (1).

Transmitancja	Opis
$G(s) = \frac{Y(s)}{R(s)} = \frac{G_R(s)G_O(s)}{1+G_R(s)G_O(s)}$	Transmitancja wypadkowa - od wartości zadanej do wyjścia układu regulacji.
$S(s) = \frac{E(s)}{R(s)} = \frac{1}{1+G_R(s)G_O(s)}$	Transmitancja uchybowa - od wartości zadanej do uchybu regulacji. Nazywana również funkcją wrażliwości.
$Z_D(s) = \frac{Y(s)}{D(s)} = \frac{G_O(s)}{1+G_R(s)G_O(s)}$	Transmitancja zakłóceniowa - od obciążenia do wyjścia. Nazywana funkcją wrażliwości na obciążenie.
$Z_N(s) = \frac{U(s)}{N(s)} = \frac{G_R(s)}{1+G_R(s)G_O(s)}$	Transmitancja od szumu pomiarowego do sterowania. Nazywana funkcją wrażliwości sterowania na szum pomiarowy.
$G_U(s) = \frac{U(s)}{R(s)} = \frac{G_R(s)}{1+G_R(s)G_O(s)}$	Transmitancja od wartości zadanej do sterowania.
$G_{otwarty}(s) = G_R(s)G_O(s)$	Transmitancja układu otwartego.

Tabela 1: Transmitancje opisujące układ regulacji automatycznej z rysunku (1).

Układ regulacji automatycznej jest **wewnętrznie** stabilny, jeśli:

- dla wszystkich warunków początkowych
- wszystkie stany dynamiczne w URA pozostają ograniczone w przypadku wzbudzenia układu ograniczonymi sygnałami gdziekolwiek w pętli sterowania

Jest to silniejsza cecha stabilności niż stabilność **zewnętrzna**, która dotyczy tylko stabilności transmitancji wypadkowej $G(s)$. Różnica polega na tym, że w transmitancji wypadkowej może dochodzić do skrócenia niestabilnych biegunów i zer. Na przykład: niestabilny biegun występujący w transmitancji obiektu skraca się z niestabilnym zerem zaprojektowanym w regulatorze. Pomimo, że takie zero i biegun skracają się w $G(s)$, to transmitancja zakłóceniowa $Z_D(s)$ nadal zawierałaby niestabilne bieguny, co oznacza, że układ regulacji automatycznej nie będzie wewnętrznie stabilny.

Aby URA był **wewnętrznie** stabilny, każda z tych transmitancji z Tabeli 1 musi być co najmniej stabilna.

Ponadto można zauważyć, że $G(s)$ i $S(s)$ są komplementarne, tzn.:

$$G(s) + S(s) = \frac{G_R(s)G_O(s)}{1 + G_R(s)G_O(s)} + \frac{1}{1 + G_R(s)G_O(s)} = 1,$$

zatem optymalizując wskaźnik jakości związany z jedną z nich, optymalizujemy automatycznie analogiczny wskaźnik jakości związany z drugą.

1.2 Wskaźniki jakości URA

Do oceny działania URA stosuje się różne wskaźniki jakości, zwane również funkcją celu. W zależności od doboru wskaźnika jakości, parametry układu będą dobierane w inny sposób.

1.2.1 Całkowe wskaźniki jakości

Jednymi z najczęściej używanych wskaźników jakości są tzw. całkowe wskaźniki jakości:

- (a) całka z kwadratu uchybu sterowania (ang. *Integral Square Error* - **ISE**):

$$J_1 = \int_0^\infty e(t)^2 dt, \quad (1)$$

- (b) całka z p -tej potęgi uchybu regulacji (aby wskaźnik taki miał sens p musi być parzyste):

$$J_2 = \int_0^\infty e(t)^p dt, \quad (2)$$

- (c) całka z modułu uchybu sterowania (ang. *Integral Absolute Error* - **IAE**):

$$J_3 = \int_0^\infty |e(t)| dt, \quad (3)$$

- (d) całka ważona względem czasu sterowania (aby wskaźnik taki miał sens p musi być parzyste) (ang. *Integral Time-weighted Square Error* - **ITSE**):

$$J_4 = \int_0^\infty e(t)^p t^q dt, \quad (4)$$

- (e) całka z kwadratu uchybu sterowania i jej pochodnej:

$$J_5 = \int_0^\infty (e(t)^2 + \dot{e}(t)^2) dt, \quad (5)$$

- (f) w przypadku rozpatrywania przestrzeni stanu można rozpatrywać całkę z dodatnio określonej formy kwadratowej stanu:

$$J_6 = \int_0^\infty x^T(t) H x(t) dt, \quad H = H^T > 0, \quad (6)$$

- (g) całka z kwadratu wyjścia układu regulacji (ang. *Integral Square Output* - **ISO**) (dla stabilizacji w zerze):

$$J_7 = \int_0^\infty y^2(t) dt, \quad y(t) \in \mathbb{R} \quad (7)$$

- (h) wskaźnik mieszany uwzględniający koszt sterowania:

$$J_8 = \int_0^\infty (\alpha_1 e(t)^2 + \alpha_2 u(t)^2) dt, \quad \alpha_1, \alpha_2 \in \mathbb{R}_+. \quad (8)$$

- (i) wskaźnik mieszany wykorzystywany w sterowniku LQR:


$$J_{LQR} = \int_0^\infty (x^T(t) H x(t) + u^T(t) F u(t)) dt, \quad H = H^T > 0, \quad F = F^T > 0. \quad (9)$$

Przykład

Różne wskaźniki jakości mogą prowadzić do różnych optymalnych nastaw regulatora, a co za tym idzie, do różnych przebiegów sygnałów w układzie regulacji. Poniżej przedstawiono przebiegi sygnału wyjściowego układu regulacji oraz sygnału sterującego dla różnych wskaźników jakości obiektu o transmitancji:

$$G(s) = \frac{1}{s(s+1)^2},$$

z użyciem regulatora proporcjonalnego.



Rysunek 2: Przebiegi dla optymalizacji względem różnych wskaźników jakości.


W powyższych definicjach całkowych wskaźników jakości jako czas górnej granicy całkowania przyjęto nieskończoność, co jest uzasadnione teoretycznie, ponieważ dla stabilnych układów regulacji sygnały $e(t)$, $u(t)$ i $y(t)$ dążą do zera, a więc całki te są skończone. W dodatku jest to też dogodne dla obliczeń analitycznych.

Jednak niejednokrotnie interesujący jest tylko skończony horyzont, np. z powodu pewnych ograniczeń czasowych w układzie sterowania. Dobór skończonego czasu staje się jednak koniecznością, gdy dokonujemy optymalizacji numerycznej, ponieważ w praktyce nie jesteśmy w stanie dokonać całkowania do nieskończoności, a zamiast tego musimy przyjąć pewien skończony czas, który jest wystarczająco duży, aby uchyb regulacji i inne sygnały były bliskie zeru.

1.2.2 Niecałkowe wskaźniki jakości

- (a) czas regulacji τ_r - jest to najmniejszy czas, począwszy od którego wartość sygnału wyjściowego obiektu nie różni się od wartości w stanie ustalonej $y_\infty = \lim_{t \rightarrow \infty} y(t)$ nie bardziej niż zadany procent γ :


$$\tau_1 = \sup\{t \in [0, \infty) : |y(t) - y_\infty| > \gamma|y_\infty|\},$$



Rysunek 3: Czas regulacji.

- (b) czas narastania τ_n - jest to czas, w którym sygnał wyjściowy $y(t)$ narasta od 10% do 90% wartości w stanie ustalonym y_{infty} :


$$\tau_2 = \min\{t \in [0, \infty) : y(t) = 0.9y_{\infty}\} - \min\{t \in [0, \infty) : y(t) = 0.1y_{\infty}\},$$



Rysunek 4: Czas narastania.

- (c) przeregulowanie κ - stosunek maksymalnej wartości sygnału wyjściowego y_{max} do wartości w stanie ustalonym:

$$\kappa = \frac{y_{max} - y_{\infty}}{y_{\infty}}$$




Rysunek 5: Przeregulowanie.

(d) uchyb ustalony e_∞ - jest to wartość uchybu regulacji w stanie ustalonym:

$$e_\infty = \lim_{t \rightarrow \infty} e(t)$$

(e) zapas modułu Δ_L - różnica między poziomem modułu równego jeden, a poziomem modułu $L(\omega_1)$ transmitancji widmowej $G_{otwarty}(i\omega)$, gdzie ω_1 jest pulsacją, dla której faza transmitancji widmowej $\varphi(\omega_1) = -\pi$.

(f) zapas fazy Δ_φ - jest różnicą między argumentem $\varphi(\omega_2)$ transmitancji widmowej $G_{otwarty}(i\omega)$, dla której moduł $|G_{otwarty}(i\omega)|$ wynosi 1, a wartością $-\pi$.



Rysunek 6: Zapas fazy i modułu.

1.3 Wyznaczanie całkowych wskaźników jakości na podstawie transmitancji

(a) $J_1 = \int_0^\infty e(t)^2 dt$: do wyznaczenia całki z kwadratu uchybu sterowania $e(t)$ na podstawie znajomości jego transformaty $E(s) = \frac{B(s)}{A(s)}$, gdzie stopień wielomianu $A(s)$ jest wyższy niż wielomianu $B(s)$, można wykorzystać równość, wynikającą z twierdzeń Reileigha i Persevala:

$$J_1 = \int_0^\infty e(t)^2 dt = \frac{1}{2\pi} \int_{-i\infty}^{+i\infty} E(s)E(-s)ds.$$

Dokładne wyprowadzenie zależności na analityczne wyznaczenie tej całki można znaleźć w pracach [1] i [8]. W tej instrukcji ograniczymy się do zaznaczenia, że wyznaczana jest ona poprzez poszukiwanie wielomianu:

$$C(s) = c_{n-1}s^{n-1} + \dots + c_1s + c_0,$$

który spełnia zależność:

$$B(s)B(-s) = A(-s)C(s) + A(s)C(-s).$$

Na podstawie tej równości dostajemy zestaw równań na wartości współczynników c_i , wynikających z równości odpowiednich współczynników wielomianów z lewej i prawej strony znaku równości. A ostateczną formułą na wskaźnik jakości J_1 jest (1):

$$J_1 = \frac{c_{n-1}}{a_n}. \quad (10)$$

- (b) $J_4 = \int_0^\infty e(t)^p t^q dt$: stosunkowo prostą analityczną formę na wskaźnik jakości ważony czasem sterowania można przedstawić dla $p = 2$ oraz dla $q = 2$. Można ją wyznaczyć poprzez podstawienie:

$$\gamma(t) = te(t),$$

wówczas wskaźnik jakości ma postać:

$$J_4 = \int_0^\infty \gamma(t)^2 dt.$$

A ponieważ transformatę $\gamma(t)$ można przedstawić jako:

$$\Gamma(s) = -\frac{\partial E(s)}{ds},$$

to można zastosować procedurę jak dla wskaźnika J_1 tylko z transformatą $\Gamma(s)$.

- (c) $J_5 = \int_0^\infty (e(t)^2 + \dot{e}(t)^2) dt$: całkę tę można rozbić na sumę:

$$J_5 = \int_0^\infty e(t)^2 dt + \int_0^\infty \dot{e}(t)^2 dt = J_1 + \int_0^\infty \dot{e}(t)^2 dt.$$

Część J_1 została już objaśniona, natomiast co do drugiego składnika sumy, to można zauważyć, że jego transformata będzie miała postać:

$$\dot{e}(t) \rightarrow E_p(s) = sE(s).$$

Zatem powtarzamy postępowanie dla J_1 , ale z transformatą $E_p(s)$.

- (d) $J_7 = \int_0^\infty y^2(t) dt$ - całka z kwadratu wyjścia układu regulacji może zostać wyznaczona z wykorzystaniem równania Lapunowa:

$$A^T P + PA = -cc^T, P = P^T > 0.$$

Wówczas jeśli istnieje rozwiązanie tego równania, to układ jest stabilny i posiada funkcję Lapunowa $V(x) = x^T P x$ a jej pochodna wzdłuż trajektorii układu wynosi $\dot{V}(x) = -x^T (A^T P + PA) x$. Natomiast wskaźnik jakości J_8 jest skończony i wynosi:

$$J_7 = x^T(0) P x(0).$$

Ponieważ:

$$\begin{aligned} J_7 &= \int_0^\infty y^2(t) dt = \int_0^\infty x^T(t) c c^T x(t) dt = \\ &= - \int_0^\infty x^T(t) (A^T P + PA) x(t) dt = - \int_0^\infty \dot{V}(x(t)) dt = - [V(x(t))] |_0^\infty = \\ &= - \lim_{t \rightarrow \infty} [V(x(t))] + V(x(0)) = 0 + V(x(0)) = x^T(0) P x(0). \end{aligned}$$

1.4 Wyznaczanie niecałkowych wskaźników jakości

W ogólności trudno jest wyznaczyć analityczne zależności na przeregulowanie czy czas narastania. Możliwe jest to jednak dla układów drugiego rzędu, i na tych układach się tutaj skupimy. W tym celu przyjmijmy następującą parametryzację obiektu drugiego rzędu:

$$G_{II}(s) = \frac{\omega_n^2}{s^2 + 2\xi\omega_n s + \omega_n^2} = \frac{k}{(s + \sigma)^2 + \omega_d^2}$$

gdzie:

- ω_n - pulsacja drgań własnych,
- ξ - współczynnik tłumienia,
- σ - tłumienie względne,
- ω_d - pulsacja drgań tłumionych.

(a) *Czas regulacji* - dla $\gamma = 0.02$ - dla takiego poziomu uchybu regulacji przybliżony czas regulacji można przedstawić jako:

$$\tau_r = \frac{4}{\xi\omega_n},$$

(b) *Przeregulowanie* - przeregulowanie można określić na podstawie wzoru:


$$\kappa = e^{-\frac{\pi\xi}{\sqrt{1-\xi^2}}},$$

natomiast czas pierwszego maksimum to:

$$t_p = \frac{\pi}{\omega_n\sqrt{1-\xi^2}}.$$

1.5 Optymalizacja wielokryterialna

W praktyce inżynierskiej bardzo często spotykane są problemy, które wymagają optymalizacji względem więcej niż jednego kryterium. Nierzadko nie są one wzajemnie przeliczalne, więc nie można ich sprowadzić do pojedynczego skalarnego przypadku. Ponadto bywa, iż kryteria, względem których wykonujemy optymalizację, są wzajemnie sprzeczne - jak np. żądanie jak najszybszej reakcji na zmiany wartości zadanej i minimalizacja energii sterowania. Formalnie można zapisać, że zadanie optymalizacji wielokryterialnej jest poszukiwaniem minimum wektora wskaźników jakości $F(x) = [F_1 \ \dots \ F_n] \in R^n$. Jednak problematyczne jest określenie, czym właściwie jest minimum wektora. Gdyż minimum dla każdego z kryteriów osiągane jest zwykle w innym punkcie. Dlatego poszukuje się rozwiązań kompromisowych, na tzw. zbiorze (froncie) Pareto, będącym zbiorem rozwiązań, dla których co najmniej jedno kryterium osiąga lepszy wynik niż dla innych punktów - rysunek (7).



Rysunek 7: Zbiór (front) Pareto.

Nierzadko jednak można zadanie to uprościć i zastosować i stosować pewne uproszczenia, najczęściej są to:

- **Metoda skalaryzacji**, która polega na przekształceniu zadania optymalizacji wielokryterialnej w zadanie optymalizacji skalarnej poprzez nadanie każdemu ze wskaźników jakości wagi i zsumowanie ich:

$$\mathbf{F} = \nu F = \sum_i^n \nu_i F_i, \nu_i > 0.$$

Można wówczas pokazać, że jeśli $\hat{\mathbf{F}}$ jest minimum lokalnym, to odpowiadający mu wektor F leży na zbiorze Pareto. Wagi ν_i odzwierciedlają priorytety projektanta. Ważne jest, aby suma wag była równa jedności ($\sum \nu_i = 1$) oraz aby poszczególne wskaźniki F_i były znormalizowane (sprowadzone do wspólnego rzędu wielkości). W przeciwnym razie wskaźnik o większej wartości bezwzględnej zdominuje pozostałe, niezależnie od przypisanej mu wagi.

- **Metoda ograniczeń**, która polega na wybraniu jednego z kryteriów jako funkcji celu, a pozostałe traktuje się jako ograniczenia, które muszą być spełnione:

$$\min F_1(x) \quad \text{przy} \quad F_i(x) \leq \varepsilon_i, i = 2, \dots, n,$$

gdzie ε_i to dopuszczalne poziomy dla pozostałych kryteriów. W ten sposób można skupić się na optymalizacji jednego kryterium, jednocześnie zapewniając, że pozostałe nie przekroczą określonych wartości. Jednak wybór odpowiednich poziomów ε_i może być trudny i wymagać eksperymentowania, aby znaleźć kompromis między różnymi kryteriami.

- **Metoda punktu utopijnego** polega na zdefiniowaniu punktu utopijnego, który reprezentuje idealne wartości wszystkich kryteriów (zwykle jest to punkt, w którym wszystkie kryteria osiągają swoje minimum i jest niemożliwe do osiągnięcia). Następnie poszukuje się rozwiązania, które jest jak najbliżej tego punktu utopijnego, mierząc odległość między kandydatami a punktem utopijnym. Najczęściej stosowaną miarą odległości jest norma euklidesowa:

2 Przykłady

2.1 Przykład 1

Rozważmy obiekt o transmitancji:

$$G(s) = \frac{s+1}{s(s^2+s+1)}$$

w układzie regulacji automatycznej z rysunku (1), z regulatorem:

- (a) typu P: $G_{R,P}(s) = K_P$,
- (b) typu PI: $G_{R,PI}(s) = K_P(1 + \frac{1}{T_i s})$ zakładając, że $T_i, K_P > 0$.

Znaleźć optymalne nastawy względem wskaźnika jakości J_1 i J_7 (dla $\alpha_1 = \alpha_2 = 1$).

- (a) W celu rozwiązania zadania w pierwszej kolejności wyznaczamy transmitancję zastępczą URA:

$$G(s) = \frac{Ks + K}{s^3 + s^2 + s(K+1) + K}.$$

Wzmocnienie K musi stabilizować URA, zatem wyznaczamy zakres wartości K , dla których układ będzie stabilny, można to zrobić np. za pomocą kryterium Hurwita:

$$H = \begin{bmatrix} 1 & 1 & 0 \\ K & K+1 & 1 \\ 0 & 0 & K \end{bmatrix} \implies \Delta_1 = 1 > 0, \Delta_2 = 1 > 0, \Delta_3 = K > 0 \implies K > 0.$$

Znając zakres stabilnych K wyznaczamy transmitancję uchybową:

$$S(s) = \frac{s^3 + s^2 + s}{s^3 + s^2 + s(K+1) + K}.$$

Ponieważ $E(s) = S(s)R(s)$, to transformata odpowiedzi na skok jednostkowy wynosi:

$$E(s) = \frac{1}{s} \cdot \frac{s^3 + s^2 + s}{s^3 + s^2 + s(K+1) + K} = \frac{s^2 + s + 1}{s^3 + s^2 + s(K+1) + K}.$$

Aby wyznaczyć "produkowane" sterowanie wyznaczamy transmitancję:

$$G_U = \frac{K(s^3 + s^2 + s)}{s^3 + s^2 + s(K+1) + K}.$$

A więc transformata sterowania wynosi:

$$U(s) = \frac{1}{s} \cdot \frac{K(s^3 + s^2 + s)}{s^3 + s^2 + s(K+1) + K} = \frac{K(s^2 + s + 1)}{s^3 + s^2 + s(K+1) + K}.$$

Posiadając wyznaczone transformaty sygnałów sterowania i uchybu sterowania można wyznaczyć wskaźniki jakości:

- (1.) $J_2(K) = \int_0^\infty e(t)^2 dt$ wyznaczamy zgodnie z przedstawioną metodą analitycznego wyznaczania takiej całki na podstawie transformaty Laplace'a $E(s) = \frac{A(s)}{B(s)}$ funkcji $e(t)$. W tym celu konieczne jest wyznaczenie wielomianu $C(s) = c_2 s^2 + c_1 s + c_0$, który spełnia równanie:

$$B(s)B(-s) = A(-s)C(s) + A(s)C(-s),$$

które po rozpisaniu i pogrupowaniu wyrazów daje następujący układ równań liniowych:

$$\begin{bmatrix} 2K & 0 & 0 \\ 2 & -2-2K & 2K \\ 0 & -2 & 2 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \implies \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{K}{2} + \frac{1}{2K} - \frac{1}{2} \\ \frac{K}{2} + \frac{1}{2K} \end{bmatrix}.$$

Zatem wskaźnik jakości wynosi:

$$J_1(K) = \frac{c_2}{a_3} = \frac{K}{2} + \frac{1}{2K}.$$

Aby więc wyznaczyć optymalną wartość K mamy do rozwiązania zadanie optymalizacji z ograniczeniem nierównościowym $-K < 0$, można je rozwiązać poprzez zastosowanie warunków Khuna-Karusha-Tuckera:

$$\left\{ \begin{array}{l} \frac{\partial J_2(K)}{\partial K} + \lambda(-K) = 0 \\ -K < 0 \\ \lambda(-K) = 0 \end{array} \right\} \implies \left\{ \begin{array}{l} \frac{1}{2} - \frac{1}{2K^2} + \lambda(-K) = 0 \\ -K < 0 \\ \lambda(-K) = 0 \end{array} \right\} \implies \left\{ \begin{array}{l} K = 1 \\ \lambda = 0 \end{array} \right\}.$$

Zatem optymalna wartość wskaźnika jakości wynosi:

$$J_1(1) = \frac{1}{2} + \frac{1}{2} = 1.$$

- (2.) $J_7(K) = \int_0^\infty (e(t)^2 + u(t)^2) dt = \int_0^\infty e(t)^2 dt + \int_0^\infty u(t)^2 dt$ - pierwsza część sumy została wyznaczona w poprzednim przypadku. Natomiast druga część, zależna tylko od sterowania, zostanie wyznaczona tutaj w analogiczny sposób, szukając odpowiedniego wielomianu $C(s) = c_2^u s^2 + c_1^u s + c_0^u$, co w tym przypadku prowadzi do układu równań:

$$\begin{bmatrix} 2K & 0 & 0 \\ 2 & -2-2K & 2K \\ 0 & -2 & 2 \end{bmatrix} \begin{bmatrix} c_0^u \\ c_1^u \\ c_2^u \end{bmatrix} = \begin{bmatrix} K^2 \\ K^2 \\ K^2 \end{bmatrix} \implies \begin{bmatrix} c_0^u \\ c_1^u \\ c_2^u \end{bmatrix} = \begin{bmatrix} \frac{K}{2} \\ \frac{K}{2}(K^2 - K + 1) \\ \frac{K}{2}(K^2 + 1) \end{bmatrix}.$$

Zatem część wskaźnika jakości związana ze sterowaniem wynosi:

$$J_7^u(K) = \frac{c_2^u}{a_3} = \frac{K}{2}(K^2 + 1).$$

Co daje całościowo wskaźnik jakości w postaci:

$$J_7(K) = K + \frac{1}{2K} + \frac{K^3}{2}.$$


A optymalną wartość K ponownie odnajdujemy poprzez rozwiązanie problemu KKT:

$$\left\{ \begin{array}{l} \frac{\partial J_7(K)}{\partial K} + \lambda(-K) = 0 \\ -K < 0 \\ \lambda(-K) = 0 \end{array} \right\} \implies \left\{ \begin{array}{l} \frac{3}{2}K^2 - \frac{1}{2K^2} + 1 + \lambda(-K) = 0 \\ -K < 0 \\ \lambda(-K) = 0 \end{array} \right\} \implies \left\{ \begin{array}{l} K = \frac{\sqrt{3}}{3} \\ \lambda = 0 \end{array} \right\}.$$


Zatem optymalna wartość wskaźnika jakości wynosi:

$$J_7\left(\frac{\sqrt{3}}{3}\right) \approx 1.5396.$$

Przebiegi czasowe uzyskanych uchybów regulacji i sterowania pokazano na rysunkach (8) i (10):




Rysunek 8: Przebiegi czasowe uchybu sterowania dla optymalnych nastaw regulatora względem wskaźnika jakości J_2 i J_7 .




Rysunek 9: Przebiegi czasowe sterowania dla optymalnych nastaw regulatora względem wskaźnika jakości J_2 i J_7 .

Obydwa przypadki, dla wskaźnika J_2 , jak i J_7 można również rozwiązać numerycznie, korzystając z modelu Simulinka, jak na rysunku (10):



Rysunek 10: Model symulacyjny używany do optymalizacji współczynników regulatora.

Na jego podstawie uzyskano praktycznie identyczne wyniki jak w rozwiązaniu analitycznym:



Rysunek 11: Wzrost wskaźnika jakości w czasie symulacji.

- (b) Podobnie jak w przypadku regulatora proporcjonalnego w celu rozwiązania zadania w pierwszej kolejności wyznaczamy transmitancję zastępczą URA z regulatorem proporcjonalno-całkującym:

$$G(s) = \frac{K_P T_I s^2 + (K_P + K_P T_I) s + K_P}{T_I s^4 + T_I s^3 + (T_I + K_P T_I) s^2 + (K_P + K_P T_I) s + K_P}.$$

Parametry K_P i T_D muszą stabilizować URA, zatem wyznaczamy zakres tych wartości, dla których układ będzie stabilny, można to zrobić np. z za pomocą kryterium Hurwitza:

$$H = \begin{bmatrix} T_I & K_P + K_P T_I & 0 & 0 \\ T_I & T_I + K_P T_I & K_P & 0 \\ 0 & T_I & K_P + K_P T_I & 0 \\ 0 & T_I & T_I + K_P T_I & K_P \end{bmatrix} \Rightarrow$$

$$\Rightarrow \Delta_1 = T_I, \Delta_2 = T_I^2 - K_P T_I, \Delta_3 = -K_P^2 T_I^2 - K_P^2 T_I + K_P T_I^3, \Delta_4 = -K_P (K_P^2 T_I^2 + K_P^2 T_I - K_P T_I^3) \Rightarrow$$

$$\Rightarrow T_i > 0, K_P < T_I, K_P < \frac{T_I^2}{T_I + 1}.$$

Znając ograniczenia na parametry regulatora wyznaczamy transformaty dla sygnałów sterowania i uchybu sterowania w odpowiedzi na skok jednostkowy - $R(s) = \frac{1}{s}$, będą to odpowiednio:

- transformata uchybu:

$$E(s) = \frac{T_I s^3 + T_I s^2 + T_I s}{T_I s^4 + T_I s^3 + (T_I + K_P T_I) s^2 + (K_P + K_P T_I) s + K_P},$$

- transformata sterowania:

$$U(s) = \frac{K_P T_I s^3 + (K_P + K_P T_I) s^2 + (K_P + K_P T_I) s + K_P}{T_I s^4 + T_I s^3 + (T_I + K_P T_I) s^2 + (K_P + K_P T_I) s + K_P}.$$

- (1.) $J_1(K) = \int_0^\infty e(t)^2 dt$ wyznaczamy metodą analityczną, jak poprzednio, szukając odpowiedniego wielomianu $C(s) = c_2 s^2 + c_1 s + c_0$, spełniającego warunek:

$$B(s)B(-s) = A(-s)C(s) + A(s)C(-s).$$

Na podstawie tej równości otrzymuje się układ równań, którego rozwiązanie daje wynik:

$$c_3 = \frac{T_I^2 (K_P^2 T_I + K_P^2 - 2 K_P T_I + T_I^2)}{2 K_P^2 (-T_I^2 + K_P T_I + K_P)}.$$

A zatem wskaźnik jakości przybiera ostatecznie:

$$J_1(K_P, T_I) = \frac{c_3}{a_4} = \frac{T_I^2 (K_P^2 T_I + K_P^2 - 2 K_P T_I + T_I^2)}{2 T_I K_P^2 (-T_I^2 + K_P T_I + K_P)}.$$

(2.) $J_7(K) = \int_0^\infty (e(t)^2 + u(t)^2) dt = \int_0^\infty e(t)^2 dt + \int_0^\infty u(t)^2 dt$ - pierwsza część sumy została wyznaczona w podpunkcie wyżej, dlatego tutaj wystarczy wyznaczyć część związaną tylko ze sterowaniem:

$$J_7^u = \frac{-K_P^2 T_I^3 - K_P^2 T_I^2 + K_P^2 T_I + K_P^2 + K_P T_I^3 - 2 K_P T_I + T_I^2}{2 T_I (-T_I^2 + K_P T_I + K_P)}.$$

Są to dość skomplikowane wyrażenia, dlatego analityczne ich wyznaczenie zostanie pominięte.

2.2 Przykład 2

Rozważamy obiekt sterowania o transmitancji:

$$G(s) = \frac{1}{s+1},$$

w układzie automatycznej regulacji, jak na rysunku (1). Z regulatorem proporcjonalno-całkującym:

$$G_{R,I}(s) = 1 + \frac{1}{T_I s}.$$

Odnaleźć nastawę regulatora, która zapewnia najlepszą wartość wskaźnika jakości J_2 , przy jednoczesnym minimalizowaniu wpływu zakłócenia obciążeniowego $D(s)$. Wskaźnik jakości można zapisać zatem jako sumę:

$$J(T_I) = J_{1,E} + J_{1,D}$$

gdzie:

- $J_{1,E} = \int_0^\infty e(t)^2 dt$ - całka z uchybu sterowania w odpowiedzi na skok jednostkowy na wartości zadanej,
- $J_{1,D} = \int_0^\infty d(t)^2 dt$ - całka z wyjścia w odpowiedzi na skok jednostkowy na obciążeniu.

Podobnie jak poprzednio, zaczynamy od wyznaczenia transmitancji zastępczej i sprawdzenia zakresu wartości T_I , które stabilizują układ po zamknięciu sprzężenia zwrotnego:

$$G(s) = \frac{T_I s + 1}{T_I s^2 + 2 T_I s + 1}.$$

Łatwo zauważyć, iż wystarczy aby $T_I > 0$, aby układ był stabilny.

Kolejno wyznaczamy transmitancje:

- uchybową:

$$S(s) = \frac{T_I s^2 + T_I s}{T_I s^2 + 2 T_I s + 1},$$

- obciążeniową:

$$G_D(s) = \frac{T_I s}{T_I s^2 + 2 T_I s + 1}.$$

A dalej na ich podstawie transformaty odpowiedzi na skok jednostkowy:

- na wartości zadanej:

$$E(s) = \frac{T_I s + T_I}{T_I s^2 + 2 T_I s + 1},$$

- na obciążeniu:

$$Y(s) = \frac{T_I}{T_I s^2 + 2 T_I s + 1}.$$

Znając te transformaty wyznaczamy składniki wskaźnika jakości:

- $J_{1,E} = \frac{T_I}{4} + \frac{1}{4}$,
- $J_{1,D} = \frac{1}{4}$.

Sumarycznie otrzymujemy:

$$J(T_I) = \frac{T_I}{4} + \frac{1}{2}.$$

Zatem nie ma minimum, ale współczynnik jakości poprawia się wraz ze zmniejszaniem T_I .

3 Jak to zrobić w MATLABie?

3.1 Optymalizacja bez ograniczeń

MATLAB Symbolic Toolbox dostarcza kilka funkcji służących do rozwiązywania problemów optymalizacji bez ograniczeń. Są to np.:

- **fminsearch** - funkcja ta rozwiązuje problem optymalizacji metodami bezgradientowymi, jej przykładowe użycie to:

```
fun = @(x)(x(1)^2 + x(2));      % Uchwyty do minimalizowanej
                                % funkcji
x_0 = [1; 1];                  % Warunek początkowy
x_opt = fminsearch(fun, x_0);   % Uruchomienie procedury
                                % minimalizacyjnej
```

- **fminunc** - funkcja ta rozwiązuje problem optymalizacji metodami gradientowymi, gdzie gradient funkcji celu może być podany analitycznie przez użytkownika, lub w przypadku, gdy jest trudnoosiągalny, może być aproksymowany numerycznie wewnątrz funkcji **fminunc**. Jej przykładowe użycie to:

```
% Definicja minimalizowanej funkcji - może zwracać dodatkowo
% gradient
function [f,g] = rosenbrockwithgrad(x)
% Minimalizowana funkcja
f = 100*(x(2) - x(1)^2)^2 + (1-x(1))^2;

% Gradient
if nargin > 1
    g = [-400*(x(2)-x(1)^2)*x(1) - 2*(1-x(1));
         200*(x(2)-x(1)^2)];
end

fun = @rosenbrockwithgrad;      % Uchwyty do minimalizowanej funkcji
x_0 = [1; 1];                  % Warunek początkowy
x_opt = fminsearch(fun, x_0);   % Uruchomienie procedury
                                % minimalizacyjnej
```

3.2 Optymalizacja z ograniczeniami

Zadanie optymalizacji z ograniczeniami, z użyciem metod gradientowych, można rozwiązać w MATLABie za pomocą funkcji **fmincon**, z Optimization Toolbox. Uwzględnia ona następujące ograniczenia:

$$\left\{ \begin{array}{ll} c(x) \leq 0 & \text{nieliniowe ograniczenia nierównościowe} \\ c_{eq}(x) = 0 & \text{nieliniowe ograniczenia równościowe} \\ Ax \leq b & \text{liniowe ograniczenia nierównościowe} \\ A_{eq}x \leq b_{eq} & \text{liniowe ograniczenia równościowe} \\ x_l \leq x \leq x_u & \text{ograniczenie na dolną i górną wartość} \end{array} \right\}$$

Jeśli minimalizowana funkcja znana jest w postaci analitycznej, to można podać jawnie wartość jej gradientu, jednak gdy nie możemy go jawnie wyznaczyć, to funkcja użyje przybliżenia numerycznego.

Dla przykładu przedstawiona zostanie minimalizacja funkcji Rosenbrocka:

```

function [f,g] = rosenbrockwithgrad(x)
    % Minimalizowana funkcja
    f = 100*(x(2) - x(1)^2)^2 + (1-x(1))^2;

    % Gradient
    if nargin > 1
        g = [-400*(x(2)-x(1)^2)*x(1)-2*(1-x(1));
            200*(x(2)-x(1)^2)];
    end

```

Ustawiamy opcje minimalizacji

```

options = optimoptions("fmincon", ...
    "SpecifyObjectiveGradient", true, ...
    "Display", "iter", ...
    "PlotFcn", @optimplotfval, ...
    "OptimalityTolerance", 1e-8 ...
);

```

Minimalizacja

```

fun = @rosenbrockwithgrad;
x0 = [-1,2];
A = [];
b = [];
Aeq = [];
beq = [];
lb = [-2,-2];
ub = [2,2];
nonlcon = @(x)100*(x(2)-x(1)^2)^2 + (1-x(1))^2;
x = fmincon(fun, x0, A, b, Aeq, beq, lb, ub, nonlcon, options);

```

3.3 Analityczne rozwiązywanie zadania optymalizacji

Analityczne rozwiązanie zadania optymalizacji może polegać na analitycznym wyznaczeniu wskaźnika jakości w postaci $J_1 = \frac{c_{n-1}}{a_n}$, a następnie numerycznej optymalizacji tej funkcji. Może być to zrealizowane tak jak w poniższym skrypcie:

```

%% Definicja transmitancji - funkcja tf() nie obsługuje zmiennych
symbolicznych
syms K_P
syms Gr(s) Go(s)
Gr(s) = K_P;
Go(s) = (s+1) / (s^3 + s^2 + s);

Gopen(s) = Gr(s)*Go(s);
G(s) = Gopen(s) / (1 + Gopen(s));
S(s) = 1 / (1 + Gopen(s));
Gu(s) = Gr(s) / (1 + Gopen(s));

%% Badanie stabilnosci - sprawdzenie warunkow wynikajacych z kryterium
Hurwitza
[~, den_closed] = numden(G);
[den_closed_coeffs, ~] = coeffs(den_closed, s);
den_closed_coeffs_array = den_closed_coeffs(s);

[H, delta] = hurwitz(den_closed_coeffs_array);

solve(delta > 0, K_P)

```

```

%% Transformacja uchybowa - wyznaczenie odpowiedzi transmitancji
    uchybowej na skok jednostkowy
[num_e, den_e] = numden(S / s);

% Wypisanie formuł LateXa dla mianownika i licznika transformaty e(t)
clc;
[num_e_coeffs, ss] = coeffs(num_e, s);
latex(sum(num_e_coeffs .* ss))

[den_e_coeffs, ss] = coeffs(den_e, s);
latex(sum(den_e_coeffs .* ss))

% Wyznaczenie wielomianu C(s)
syms c0 c1 c2
C(s) = c2*s^2 + c1*s + c0;

left = num_e(s)*num_e(-s);
left_coeffs = coeffs(left, s);
right = den_e(-s)*C(s) + den_e(s)*C(-s);
right_coeffs = coeffs(right, s);

conditions = [ ...
    left_coeffs(1) == right_coeffs(1); ...
    left_coeffs(2) == right_coeffs(2); ...
    left_coeffs(3) == right_coeffs(3) ...
];
c_solved = solve(conditions, [c0,c1, c2]);

% Wyznaczenie wskaźnika jakości J_1
c_2 = c_solved.c2;
latex(c_2)

den_e_array = den_e_coeffs(s);
a3 = den_e_array(1);

J = c_2 / a3;

% Optymalizacja numeryczna wskaźnika jakości
j_numeric_e = @(x)(double(subs(J, {K_P}, x)));

options = optimoptions("fmincon", ...
    "Display", "iter", ...
    "PlotFcn", @optimplotfval, ...
    "OptimalityTolerance", 1e-4 ...
);

x0 = [5];
A = [];
b = [];
Aeq = [];
beq = [];
lb = [0];
ub = [];
nonlcon = [];
x_opt_e = fmincon(j_numeric_e, x0, A, b, Aeq, beq, lb, ub, nonlcon,
    options);

```

```

%% Transformacja obciazeniowa - wyznaczenie odpowiedzi transmitancji
    obciazeniowej na skok jednostkowy
[num_u, den_u] = numden(Gu / s);

% Wypisanie formuL LateXa dla mianownika i licznika transformaty e(t)
clc;
[num_u_coeffs, ss] = coeffs(num_u, s);
latex(sum(num_u_coeffs .* ss))

[den_u_coeffs, ss] = coeffs(den_u, s);
latex(sum(den_u_coeffs .* ss))

% Wyznaczenie wielomianu C(s)
syms c0 c1 c2
C(s) = c2*s^2 + c1*s + c0;

left = num_u(s)*num_u(-s);
left_coeffs = coeffs(left, s);
right = den_u(-s)*C(s) + den_u(s)*C(-s);
right_coeffs = coeffs(right, s);

conditions = [ ...
    left_coeffs(1) == right_coeffs(1); ...
    left_coeffs(2) == right_coeffs(2); ...
    left_coeffs(3) == right_coeffs(3) ...
];
c_solved = solve(conditions, [c0,c1, c2]);

% Wyznaczenie wskaznika jakosci J_1 dla u(t)
c_2 = c_solved.c2;
latex(c_2)

den_e_array = den_e_coeffs(s);
a3 = den_e_array(1);

J = c_2 / a3;

% Optymalizacja numeryczna dla sumy e(t)^2 + u(t)^2
j_numeric_eu = @(x)(j_numeric_e(x) + double(subs(J, {K_P}, x)));

options = optimoptions("fmincon", ...
    "Display", "iter", ...
    "PlotFcn", @optimplotfval, ...
    "OptimalityTolerance", 1e-4 ...
);

x0 = [5];
A = [];
b = [];
Aeq = [];
beq = [];
lb = [0];
ub = [];
nonlcon = [];
x_opt_eu = fmincon(j_numeric_eu, x0, A, b, Aeq, beq, lb, ub, nonlcon,
    options);

```

3.4 Sumylacyjne rozwiązywanie zadania optymalizacji

W sytuacji, gdy nie znamy analitycznej formuły na wskaźnik jakości, np. z powodu jego znacznego skomplikowania, można posłużyć się wynikami symulacyjnymi. Można w tym celu wykorzystać model jak na rysunku (10), w którym wyznaczone są odpowiednie przebiegi i całki. Wówczas można użyć jednej z podanych wyżej funkcji optymalizacyjnych z funkcją celu, zdefiniowaną w MATLABie jako:

```
function j = wskaznik_jakosci(x)
    global KP TI
    KP = x(1);
    TI = x(2);
    output = sim("ura.slx");
    j = output.je.Data(end) + output.ju.Data(end);
end
```

4 Regulator liniowo-kwadratowy

4.1 Reguła optymalności Bellmana

Reguła optymalności Bellmana jest to zasada, która mówi, że optymalne sterowanie w danym momencie czasu zależy tylko od aktualnego stanu systemu, a nie od historii jego wcześniejszych stanów. Oznacza to, że jeśli znamy sterowanie optymalne dla każdego możliwego stanu systemu, to możemy zbudować optymalną strategię działania dla całego procesu decyzyjnego, wybierając optymalne sterowanie dla aktualnego stanu systemu w każdym momencie czasu. Inaczej można sformułować tę regułę, mówiąc, że jeśli pewna trajektoria jest optymalna dla pewnego stanu początkowego i czasu początkowego t_0 oraz końcowego t_f , to wszystkie podtrajektorie tej trajektorii odpowiadające przedziałowi czasu $[t_1, t_f]$ dla $t_0 < t_1 < t_f$ są również optymalne dla stanu początkowego w czasie t_1 i końcowego w czasie t_f . Reguła optymalności Bellmana jest podstawą dla wielu algorytmów optymalizacji, takich jak dynamiczne programowanie, które są szeroko stosowane w teorii sterowania i optymalizacji.

W przypadku poszukiwania optymalnej strategii sterowania dla systemu dynamicznego:

$$\dot{x}(t) = f(x(t), u(t)),$$

z funkcjonalem jakości:

$$J(x, u) = \int_{t_0}^{t_f} L(x(t), u(t)) dt,$$

reguła optymalności Bellmana może być wykorzystana do wyznaczenia funkcji wartości

$$V(x, t) = \min_u J(x, u),$$

która określa wartość optymalnej strategii dla każdego możliwego stanu systemu.

Co można zapisać w postaci:

$$V(x, t) = \min_u \{L(x(t), u(t))\Delta t + V(x + \dot{x}\Delta t, t + \Delta t)\},$$

przy $\Delta t \rightarrow 0$.

Jeśli teraz policzymy pochodną funkcji wartości względem czasu, to otrzymamy równanie:

$$-\frac{\partial V}{\partial t} = \min_u \left\{ \underbrace{L(x(t), u(t))}_{\text{aktualny przyrost kosztu}} + \underbrace{\frac{\partial V}{\partial x} f(x(t), u(t))}_{\text{przyrost kosztu w przyszłości wynikający z aktualnej akcji}} \right\}$$

Zatem sterowanie u^* minimalizujące prawą stronę równania zapewnia najmniejszy możliwy przyrost funkcji wartości - czyli zerowy dla ciągu optymalnych sterowań w całej przyszłości, a zatem jest optymalnym sterowaniem:

$$0 = \min_u \{L(x(t), u(t)) + \frac{\partial V}{\partial x} f(x(t), u(t))\}, \quad (11)$$

równanie to nazywane jest równaniem Hamiltona-Jacobiego-Bellmana.

W ogólności równanie Hamiltona-Jacobiego-Bellmana jest bardzo trudne do rozwiązania, ale w przypadku problemu liniowo-kwadratowego można znaleźć jego rozwiązanie analityczne, co zostanie pokazane w następnej sekcji.

Uwaga

Częściej można spotkać w praktyce regułę optymalności Bellmana w formie dyskretnej, gdzie czas jest dyskretyzowany na kroki, a funkcja wartości jest definiowana jako suma przyszłych kosztów, a nie całka:

$$V(x) = \max_u \left\{ L(x, u) + \gamma \sum_{x'} P(x'|x, u) V(x') \right\},$$

gdzie:

- $V(x)$ jest funkcją wartości dla stanu x , która określa maksymalną sumę przyszłych nagród, jaką można uzyskać, zaczynając od stanu x ,
- $L(x, u)$ jest natychmiastowym kosztem (lub nagrodą) za podjęcie akcji u w stanie x ,
- γ jest współczynnikiem dyskontowym, który określa, jak bardzo przyszłe koszty są dyskontowane w stosunku do natychmiastowych kosztów,
- $P(x'|x, u)$ jest prawdopodobieństwem przejścia do stanu x' po podjęciu akcji u w stanie x .

Jest to fundamentalne równanie dla metod sterowania z wykorzystaniem uczenia maszynowego - uczenia z wzmocnieniem (ang. Reinforcement Learning). Takich jak Q-learning, gdzie funkcja wartości jest aproksymowana za pomocą sieci neuronowej, a sterowanie jest wybierane na podstawie tej funkcji wartości.

4.2 Problem liniowo-kwadratowy

Problem liniowo-kwadratowy jest to problem optymalizacji, w którym celem jest minimalizacja wskaźnika jakości w postaci:

$$J = \int_0^\infty (x(t)^T H x(t) + u(t)^T F u(t)) dt \implies L(x, u) = x(t)^T H x(t) + u(t)^T F u(t),$$

przy czym układ jest opisywany liniowym równaniem stanu:

$$\dot{x}(t) = Ax(t) + Bu(t),$$

gdzie A i B są macierzami systemu, a H i F są macierzami wag dla stanu i sterowania odpowiednio.

Natomiast poszukujemy regulatora liniowego, proporcjonalnego do stanu, w postaci:

$$u(t) = -Kx(t),$$

stąd wniosek, że funkcja wartości $V(x, t)$ jest funkcją kwadratową stanu, czyli:

$$V(x, t) = x(t)^T P x(t), \text{ oraz } \frac{\partial V}{\partial x} = 2x(t)^T P,$$

gdzie P jest macierzą symetryczną, dodatnio określoną.

Podstawiając zatem powyżej zdefiniowany system i funkcję jakości do równania Hamiltona-Jacobiego-Bellmana (4.1), otrzymujemy:

$$0 = \min_u \{ x(t)^T H x(t) + u(t)^T F u(t) + 2x(t)^T P A x(t) + 2x(t)^T P B u(t) \}. \quad (12)$$

A więc różniczkując prawą stronę względem u i przyrównując do zera, otrzymujemy:

$$0 = 2F u + 2P B^T x \implies u = -F^{-1} B^T P x.$$

Zatem otrzymujemy zależność na macierz K regulatora:

$$K = F^{-1} B^T P, \quad (13)$$

w wyrażeniu tym pozostaje nam jeszcze do wyznaczenia macierz P . Można ją odnaleźć podstawiając wyrażenie na u do równania (12), co daje:

$$0 = x(t)^T H x(t) + x(t)^T P (A - B F^{-1} B^T P) x(t),$$

a zatem macierz P jest rozwiązaniem równania algebraicznego Riccatiego:

$$PA + A^T P - P B F^{-1} B^T P + H = 0. \quad (14)$$

Równanie to jest nieliniowe, ale można je rozwiązać numerycznie, np. za pomocą funkcji `care` w MATLABie, która rozwiązuje równanie algebraiczne Riccatiego dla problemu liniowo-kwadratowego.

4.3 Zastosowanie regulatora liniowo-kwadratowego

Regulator liniowo-kwadratowy jest szeroko stosowany w praktyce. Jest on szczególnie użyteczny w sytuacjach, gdy chcemy zminimalizować zarówno odchylenie stanu od wartości zadanej, jak i wielkość sterowania, co jest często pożądane w praktyce, aby uniknąć nadmiernego zużycia energii lub nadmiernego obciążenia elementów wykonawczych.

Problematycznym zagadnieniem jest jednak dobór odpowiednich wag w macierzach H i F , które określają, jak bardzo karane są odchylenia stanu i wielkość sterowania. Nie ma jasnego przełożenia tych wag na konkretne cechy odpowiedzi układu, takie jak przeregulowanie, czas narastania, występowanie oscylacji, itp. Dlatego dobór tych wag jest często procesem iteracyjnym, który wymaga eksperymentowania i dostosowywania ich wartości w celu osiągnięcia pożądanej charakterystyki odpowiedzi układu.

Uwaga

Pamiętać należy, że istotny jest stosunek F i H , a nie tylko ich konkretne wartości. Jeśli przemnożymy dla przykładu F i H przez tę samą stałą, to otrzymamy ten sam regulator, ponieważ K jest zależne od stosunku tych macierzy, a nie od ich konkretnych wartości.

Literatura

- [1] Mitkowski, W., Baranowski, J., Hajduk, K., Korytowski, A., Tutaj, A., *Teoria Sterowania: Materiały Pomocnicze do Ćwiczeń Laboratoryjnych*, AGH Uczelniane wydawnictwo Naukowo-Dydaktyczne, 2007.
- [2] Amborski, K., Marusak, A., *Teoria Sterowania w Ćwiczeniach*, Państwowe Wydawnictwo Naukowe, 1978.
- [3] Gessing, R., Latarnik, M., Skrzywan-Kossek, A., *Zbiór Zadań z Teorii Nieliniowych Układów Regulacji i Sterowania*, Wydawnictwo Naukowo-Techniczne, 1981.
- [4] Gibson, J. E., *Nieliniowe Układy Sterowania Automatycznego*, Wydawnictwo Naukowo-Techniczne, 1968.
- [5] Grabowski P., *Stabilność Układów Lurie*, AGH Uczelniane Wydawnictwo Naukowo-Dydaktyczne, 1999.
- [6] Vukic Z., Kuljaca L., Donlagic D., Tesnjak S., *Nonlinear Control Systems*, Marcel Dekker, 2003.
- [7] Kabziński J., *Teoria Sterowania: Projektowanie Układów Regulacji*, Państwowe Wydawnictwo Naukowe, 2020.
- [8] Górecki H., *Optymalizacja Systemów Dynamicznych*, Państwowe Wydawnictwo Naukowe, 1993.